

Gaze Tracking: Controle de Cursor em Tempo Real Baseado em Rastreamento Ocular

Guilherme S. F. Almeida, Luiz E. A. Nora, Evandro C. Vilas Boas, Felipe A. P. Figueiredo

WAI Lab e CTIoT – Instituto Nacional de Telecomunicações - Inatel

Santa Rita do Sapucaí, Brasil

guilherme.almeida@ges.inatel.br, luiz.e@ges.inatel.br, evandro.cesar@inatel.br, felipe.figueiredo@inatel.br

Abstract—Computing systems have become essential in modern society, making the development of accessible human–computer interaction solutions increasingly important. However, traditional input devices such as the mouse and keyboard can represent significant barriers for individuals with reduced mobility. This work presents a real-time cursor control system based on eye gaze tracking using only a conventional RGB camera. The proposed architecture combines face detection and landmark extraction, an initial geometric gaze estimation stage, and a lightweight neural network model for spatial refinement of the predicted coordinates. Additionally, a multi-point calibration procedure with repeated cycles is employed to reduce systematic errors in the mapping between gaze direction and cursor position. Experimental results demonstrate that the integration of structured calibration, neural refinement, and temporal smoothing improves cursor stability and control accuracy, making the proposed solution suitable for low-cost assistive applications in real-time interaction environments.

Index Terms—assistive technology, deep learning, eye tracking, real-time systems

Resumo—A dependência de sistemas computacionais torna essencial o desenvolvimento de soluções acessíveis para interação humano–computador. Entretanto, dispositivos tradicionais de entrada, como mouse e teclado, podem representar barreiras para pessoas com mobilidade reduzida. Este trabalho apresenta um sistema de controle de cursor em tempo real baseado em rastreamento ocular utilizando apenas uma câmera RGB convencional. A arquitetura proposta combina detecção facial e extração de *landmarks*, estimação geométrica inicial da direção do olhar e um modelo de rede neural leve para refinamento espacial das coordenadas estimadas. Além disso, é aplicado um procedimento de calibração multiponto com repetição em ciclos consecutivos para reduzir erros sistemáticos no mapeamento entre gaze e posição do cursor. Resultados experimentais demonstram que a integração entre calibração estruturada, refinamento neural e suavização temporal melhora a estabilidade do cursor e a precisão do controle, tornando a solução viável para aplicações assistivas de baixo custo em ambientes de interação em tempo real.

Palavras chave—deep learning, rastreamento ocular, sistemas em tempo real, tecnologia assistiva

I. INTRODUÇÃO

A dependência de tecnologias digitais e de comunicação virtual tem ampliado a demanda por soluções que promovam acessibilidade e inclusão digital. Computadores e dispositivos conectados tornaram-se ferramentas essenciais para atividades como educação, trabalho e comunicação. Entretanto, para pessoas com deficiência motora ou mobilidade reduzida, o uso de dispositivos tradicionais de entrada, como mouse e teclado, pode representar uma barreira significativa, dificultando a interação eficiente com sistemas computacionais.

Nesse contexto, tecnologias assistivas possibilitam novas formas de interação humano-computador (IHC) que não dependem exclusivamente de dispositivos físicos convencionais. Entre essas alternativas, interfaces baseadas em rastreamento ocular (*eye tracking*) têm recebido atenção por permitirem inferir a intenção do usuário a partir do movimento dos olhos, viabilizando interações naturais e sem contato manual. Tais sistemas são particularmente relevantes em cenários de acessibilidade, podendo atuar como mecanismo primário de controle para usuários com limitações motoras severas.

Sistemas de rastreamento ocular de alta precisão geralmente utilizam *hardware* especializado, como sensores infravermelhos e câmeras dedicadas capazes de detectar reflexos corneanos e estimar o vetor de gaze com elevada acurácia. Embora apresentem excelente desempenho, seu alto custo limita a adoção em larga escala. Como alternativa, pesquisas recentes investigam métodos baseados em câmeras RGB convencionais e técnicas de visão computacional para estimar a direção do olhar a partir de imagens da face ou da região ocular [1].

Com o avanço do aprendizado profundo, especialmente de redes neurais convolucionais (CNN), tornou-se possível mapear imagens oculares diretamente para coordenadas de gaze. Zhang et al. [2] demonstraram a viabilidade de métodos *appearance-based* treinados com o dataset MPIIGaze para estimativa de gaze em ambientes não controlados. Posteriormente, abordagens baseadas na face completa foram propostas para aumentar a robustez frente a variações de pose e iluminação [3]. Além disso, o sistema RT-GENE mostrou que a combinação de normalização geométrica e redes neurais profundas pode permitir estimativas de gaze em tempo real em ambientes naturais [4].

Apesar desses avanços, modelos baseados em aprendizado profundo frequentemente exigem grande poder computacional e extensos conjuntos de dados, o que pode dificultar sua aplicação em sistemas interativos em tempo real. Nesse sentido, abordagens híbridas que combinam técnicas de visão computacional com modelos neurais mais leves têm se mostrado promissoras para equilibrar precisão e eficiência computacional.

Neste contexto, este trabalho apresenta um sistema de controle de cursor baseado em rastreamento ocular em tempo real utilizando apenas uma câmera RGB convencional. A proposta integra detecção facial, extração de *landmarks*, estimativa geométrica inicial da direção do olhar e um modelo neural leve para refinamento espacial das coordenadas estimadas. Adicionalmente, é adotado um procedimento de calibração

multiponto com repetição em ciclos consecutivos, visando reduzir erros sistemáticos no mapeamento entre gaze e posição do cursor, aumentando a estabilidade do controle.

O restante do artigo está organizado da seguinte forma. A Seção II apresenta os trabalhos relacionados e a arquitetura do sistema. A Seção III descreve a metodologia adotada, incluindo dataset, arquitetura do modelo e métricas de avaliação. Em seguida, são apresentados os resultados experimentais e sua análise. Por fim, a Seção IV apresenta as conclusões e direções para trabalhos futuros.

II. TRABALHOS RELACIONADOS

A. Trabalhos Relacionados

Sistemas de rastreamento ocular podem ser classificados, de maneira geral, em três categorias principais: soluções baseadas em hardware dedicado, métodos clássicos de visão computacional e abordagens baseadas em aprendizado profundo (*deep learning*). Cada uma dessas categorias apresenta diferentes níveis de precisão, custo de implementação e requisitos computacionais, influenciando diretamente sua aplicabilidade em cenários reais de interação humano-computador.

Sistemas comerciais de rastreamento ocular normalmente utilizam iluminação infravermelha ativa e sensores especializados para capturar reflexos corneanos e estimar o vetor de gaze com elevada precisão angular. Esses sistemas exploram propriedades ópticas do olho humano, como o reflexo de Purkinje e a posição relativa da pupila, permitindo estimativas precisas do ponto de fixação do olhar. Apesar da elevada acurácia alcançada, essas soluções dependem de *hardware* dedicado e possuem custo elevado, o que limita sua adoção em aplicações de larga escala ou em ambientes com restrições orçamentárias.

Como alternativa, diversos trabalhos têm investigado técnicas baseadas em câmeras convencionais Red-Green-Blue (RGB), explorando métodos de visão computacional para estimar a direção do olhar a partir de imagens da face ou da região ocular. Hansen e Ji [1] apresentaram um levantamento abrangente sobre modelos computacionais para representação do olho e estimação de gaze, discutindo diferentes abordagens geométricas e baseadas em aparência. O estudo destaca desafios importantes para sistemas baseados em imagem, como variações de iluminação, oclusões parciais, diferenças anatômicas entre indivíduos e movimentos naturais da cabeça durante a interação.

Com o avanço do aprendizado profundo, métodos baseados em redes neurais convolucionais (CNN) passaram a desempenhar papel central na estimação de gaze a partir de imagens. Essas abordagens permitem aprender representações visuais complexas diretamente dos dados, dispensando a necessidade de modelagem geométrica explícita. Zhang et al. [2] propuseram um método *appearance-based* que utiliza uma CNN treinada com o conjunto de dados MPIIGaze, demonstrando que modelos treinados com grandes bases de dados podem estimar a direção do olhar em ambientes não controlados (*in-the-wild*). Posteriormente, Zhang et al. [3] ampliaram essa abordagem incorporando informações da face completa no processo de estimação, explorando contexto visual adicional para melhorar a robustez frente a variações de pose e iluminação.

Outro avanço relevante foi apresentado por Fischer et al. [4], que introduziram o sistema RT-GENE (*Real-Time Gaze Estimation in Natural Environments*). Esse sistema combina normalização geométrica da região facial com modelos de aprendizado profundo para estimar o vetor de gaze em tempo real, mesmo em cenários com variações significativas de pose de cabeça e condições de iluminação. A proposta demonstrou que a integração entre pré-processamento geométrico e redes neurais profundas pode melhorar a robustez da estimação em ambientes naturais.

Apesar dos avanços proporcionados pelas abordagens baseadas em aprendizado profundo, muitos desses métodos dependem de arquiteturas neurais complexas e grandes conjuntos de dados para treinamento, o que pode aumentar significativamente o custo computacional e dificultar sua aplicação em sistemas interativos executados em tempo real. Dessa forma, abordagens híbridas que combinam técnicas clássicas de visão computacional com modelos de aprendizado profundo mais leves têm se mostrado promissoras, pois permitem equilibrar precisão, eficiência computacional e viabilidade prática.

Diferentemente dos sistemas baseados exclusivamente em *hardware* infravermelho, a solução proposta neste trabalho utiliza apenas uma câmera RGB convencional, reduzindo significativamente o custo de implementação e ampliando o potencial de aplicação em contextos de acessibilidade e tecnologias assistivas.

Em comparação com abordagens puramente *appearance-based* baseadas em redes profundas, como MPIIGaze e RT-GENE, o presente trabalho adota uma estratégia híbrida que combina técnicas de visão computacional para estimativa inicial do olhar com um modelo neural leve responsável pelo refinamento espacial das coordenadas estimadas. Essa abordagem busca alcançar um equilíbrio entre precisão e custo computacional, mantendo a capacidade de execução em tempo real em *hardware* amplamente disponível.

Além disso, propõe-se um procedimento de calibração multiponto com repetição em três ciclos consecutivos (*triple-loop calibration*), com o objetivo de reduzir erros sistemáticos no mapeamento entre a direção do olhar e as coordenadas da tela. Esse aspecto é frequentemente tratado de forma simplificada em implementações baseadas apenas em *webcam*, podendo impactar negativamente a estabilidade do controle de cursor. A integração desses módulos resulta em um sistema de baixo custo, projetado para aplicações de tecnologia assistiva, com foco em estabilidade de controle, robustez a variações ambientais e viabilidade prática em cenários reais de interação humano-computador.

III. VISÃO GERAL DO SISTEMA

A arquitetura do sistema, vista na Figura 1, foi projetada para permitir controle de cursor em tempo real a partir da estimação do olhar utilizando apenas uma câmera RGB convencional. A solução adota uma abordagem modular composta por etapas sequenciais de aquisição de imagem, detecção facial, extração de características oculares, refinamento por aprendizado profundo, calibração espacial e geração de comandos para o sistema operacional. O fluxo de processamento inicia-se com a captura contínua de quadros por meio da biblioteca OpenCV. Cada




Fig. 1. Arquitetura geral do sistema de controle de cursor baseado em rastreamento ocular com integração da biblioteca `dlib` para detecção facial e landmarks.

frame é convertido e normalizado conforme necessário para reduzir ruídos e preparar os dados para as etapas subsequentes. A taxa de aquisição é mantida em regime de tempo real, garantindo responsividade adequada para interação humano-computador.

Na etapa seguinte, realiza-se a detecção facial utilizando a biblioteca `dlib`, que aplica um detector baseado em Histogram of Oriented Gradients (HOG) associado a um classificador linear. Uma vez detectada a face, o preditor de *landmarks* faciais de 68 pontos é utilizado para identificar regiões anatômicas relevantes, especialmente os contornos oculares e das pálpebras. Essa etapa fornece coordenadas estruturais que permitem isolar com precisão as regiões dos olhos, reduzindo interferências externas e variações geométricas decorrentes de pose ou inclinação da cabeça.

As regiões oculares extraídas são processadas pela biblioteca `GazeTracking`, responsável por estimar a direção inicial do olhar a partir da posição relativa das pupilas. Essa estimativa fornece informações horizontais e verticais preliminares, bem como indicadores de direção discreta (esquerda, direita ou central). Embora eficiente computacionalmente, essa abordagem geométrica pode apresentar variações decorrentes de iluminação e características individuais do usuário.

Para aumentar a robustez da estimativa espacial, as imagens oculares passam por um estágio de refinamento baseado em um modelo de rede neural totalmente conectada. As entradas são previamente redimensionadas e normalizadas para dimensão padronizada, garantindo consistência no processo de inferência. O modelo neural atua como um mecanismo de correção de erro sistemático, ajustando as coordenadas de gaze estimadas inicialmente e produzindo valores mais estáveis para mapeamento

em tela.

Uma etapa fundamental da arquitetura é o procedimento de calibração multiponto. O sistema apresenta ao usuário cinco pontos fixos distribuídos estrategicamente na tela (cantos superior esquerdo e direito, centro, cantos inferior esquerdo e direito). Para cada ponto, são coletadas múltiplas amostras de gaze, e o processo é repetido em três ciclos consecutivos (*triple-loop calibration*). A repetição permite reduzir variabilidade estatística e melhorar a estimação dos parâmetros de transformação que relacionam coordenadas oculares ao espaço bidimensional da tela.

Com os parâmetros de calibração definidos, as coordenadas refinadas do olhar são transformadas em posições X-Y compatíveis com a resolução do monitor. Um mecanismo de suavização temporal é aplicado para reduzir oscilações e tremores naturais do movimento ocular, promovendo trajetórias de cursor mais contínuas. Por fim, o controle efetivo do cursor é realizado por meio da biblioteca `pyautogui`, que converte as coordenadas calculadas em eventos de movimentação do mouse no sistema operacional. Eventos de clique podem ser acionados a partir de padrões específicos detectados na região das pálpebras, como variações prolongadas na abertura ocular.

A integração desses módulos resulta em um *pipeline* híbrido que combina técnicas clássicas de visão computacional com refinamento por aprendizado profundo, mantendo baixo custo computacional e compatibilidade com *hardware* amplamente disponível. A arquitetura foi concebida para priorizar estabilidade, responsividade e aplicabilidade prática em contextos de tecnologia assistiva.

A. Dataset

O modelo foi treinado utilizando um conjunto proprietário composto por aproximadamente 2300 imagens da região ocular, coletadas em diferentes condições de iluminação e variações de pose. Cada imagem possui um rótulo associado representando coordenadas normalizadas (x, y) no intervalo $[0, 1]$, correspondentes à posição do olhar na tela. As imagens foram redimensionadas para dimensão fixa de 224×224 pixels e normalizadas antes de serem fornecidas ao modelo.

O processo de validação do *dataset* incluiu verificação automática de consistência dos rótulos, garantindo que todos os valores fossem convertidos para ponto flutuante e permanecessem dentro do intervalo válido. Rótulos inválidos ou fora do intervalo foram tratados por substituição controlada, evitando falhas durante o treinamento. O conjunto de dados foi dividido aleatoriamente em subconjuntos de treinamento e validação, utilizando proporção de 85% para treinamento e 15% para validação.

B. Arquitetura do Modelo

O modelo adotado, denominado *AdvancedEyeTrackingCNN*, consiste em uma rede neural profunda implementada em PyTorch. A arquitetura foi projetada para estimar coordenadas contínuas bidimensionais do olhar a partir da imagem da região ocular. A saída do modelo é composta por dois neurônios lineares correspondentes às coordenadas horizontais e verticais normalizadas. A função de perda utilizada foi o Erro Quadrático Médio (*Mean Squared Error*, MSE), apropriado para regressão contínua. Para mitigar sobreajuste, foi aplicada regularização por *dropout* com taxa de 0.3. O modelo possui milhares de parâmetros treináveis, contabilizados automaticamente durante a inicialização, permitindo análise da complexidade computacional.

C. Treinamento com Scheduler Avançado

O treinamento foi conduzido por até 300 épocas utilizando mini-batches de tamanho 32. A taxa de aprendizado inicial foi definida como 10^{-3} , com ajuste dinâmico por meio de estratégias de *learning rate scheduling*. Foram implementadas múltiplas estratégias de agendamento, incluindo *Cosine annealing* com *warm-up* (configuração recomendada), *Reduce on plateau*, *Step decay*, Decaimento exponencial e *Cyclic learning rate*. Nos experimentos principais foi adotado o esquema *cosine with warmup*, que combina fase inicial de aquecimento com decaimento cossenoidal, promovendo melhor convergência e estabilidade.

O treinamento utilizou o otimizador Adam e incluiu *early stopping* com paciência de 30 épocas, *Automatic Mixed Precision* (AMP) para aceleração em GPU e salvamento automático do melhor modelo com base na métrica de validação. Durante cada época, foram registradas as seguintes métricas *Loss* de treinamento, *Loss* de validação, *acurácia@20%* (definida como proporção de predições dentro de um limite de erro aceitável) e valor instantâneo da taxa de aprendizado.

D. Interface de Sistema e Integração em Tempo Real

Após o treinamento, o modelo é integrado ao pipeline de rastreamento ocular em tempo real. As estimativas produzidas

pela rede neural refinam as coordenadas preliminares obtidas via técnicas geométricas. Um mecanismo de suavização temporal é aplicado às coordenadas preditas para reduzir oscilações naturais do movimento ocular. A posição resultante é então convertida para coordenadas absolutas da tela e enviada ao sistema operacional para controle do cursor.

E. Métricas de Avaliação

A avaliação do modelo foi conduzida sob dois aspectos. Considerou-se as métricas de treinamento Mean Squared Error (MSE) e Acurácia@20%, utilizada como métrica de tolerância espacial. Bem como métricas de rastreamento ocular: desvio médio em pixels entre posição estimada e posição alvo, erro angular médio, latência média por frame, e estabilidade temporal do cursor (variância do deslocamento). Essas métricas permitiram avaliar tanto a qualidade do aprendizado supervisionado quanto a viabilidade prática do sistema para interação humano-computador em tempo real.

IV. AVALIAÇÃO E RESULTADOS

A avaliação foi conduzida em dois níveis distintos: avaliação da rede neural em regime *offline*, analisando comportamento de treinamento e generalização interna, e avaliação do sistema integrado em tempo real, considerando desempenho computacional e aplicação prática. Na Figura 2, apresentam-se as curvas de treinamento: perda, erro euclidiano, taxa de aprendizado e *gap* treino-validação ao longo das épocas.

A. Avaliação da Rede Neural

Foram realizados múltiplos experimentos variando número de épocas (10 a 300), estratégia de *learning rate* (constante e com *scheduler*) e monitoramento do *gap* treino-validação. Nos treinamentos iniciais (10–30 épocas), observou-se redução consistente da perda de treino (de aproximadamente 0.15 para 0.09), enquanto a perda de validação apresentou oscilações significativas, atingindo valores superiores a 0.20 em alguns cenários. Esse comportamento indica instabilidade inicial e sensibilidade à taxa de aprendizado crescente. O erro euclidiano médio de treino reduziu de aproximadamente 0.55 para valores entre 0.40 e 0.42, enquanto o erro de validação apresentou picos superiores a 0.70 em alguns experimentos, caracterizando sobreajuste temporário.

Nos experimentos com maior número de épocas (60–100), utilizando estratégia de *scheduler* com crescimento inicial seguido de decaimento suave da taxa de aprendizado, observou-se comportamento mais estável com erro euclidiano de treino estabilizado entre 0.38 e 0.41, erro euclidiano de validação convergindo para faixa entre 0.40 e 0.43 e *gap* treino-validação médio entre -0.03 e -0.02. Esse comportamento indica melhor equilíbrio entre capacidade de ajuste e generalização. No experimento de maior convergência (300 épocas), com *learning rate* fixo de 10^{-4} , observou-se $\text{loss} \approx 2.5 \times 10^{-5}$, erro euclidiano médio $\approx 1.0 \times 10^{-3}$, *gap* treino-validação da ordem de 10^{-5} e $\text{Acc@10\%}$, $\text{Acc@20\%}$ e $\text{Acc@30\%} = 1.000$. A convergência simultânea das curvas de treino e validação indica ausência de *overfitting* significativo nesse cenário específico.

A análise de métrica de *gap* (*ValLoss - TrainLoss*) permitiu observar três regimes distintos: *underfitting* inicial com ambos




Fig. 2. Curvas consolidadas de treinamento: perda, erro euclidiano, taxa de aprendizado e gap treino-validação ao longo das épocas.

erros elevados e *gap* próximo de zero, *overfitting* intermediário com *gap* positivo acima de 0.10 em alguns experimentos de 50 épocas, e regime estável com *gap* negativo moderado (-0.02 a -0.03), indicando regularização implícita. A utilização do *scheduler* contribuiu para suavizar oscilações abruptas no erro de validação.

B. Avaliação do Sistema Integrado

No sistema integrado, o refinamento neural reduziu variações abruptas de coordenadas normalizadas, especialmente em regiões periféricas da tela. Os principais ganhos observados foram redução de tremores do cursor, melhoria na estabilidade em bordas da tela, trajetórias mais suaves e redução do erro espacial acumulado após calibração multiponto. Considerando resolução típica Full High Definition (Full HD, 1920×1080), erro normalizado de 0.001 implica deslocamento máximo aproximado de 1–2 pixels, o que é adequado para aplicações assistivas.

O treinamento da rede neural foi realizado no ambiente Google Colab Pro com aceleração por *Graphics Processing Unit* (GPU) NVIDIA Tesla T4 (16 GB). A avaliação do sistema integrado em tempo real foi conduzida em notebook equipado com processador Intel® Core™ i5-13420H (8 núcleos, 12 threads, até 4.60 GHz, 12 MB de cache), 8 GB de memória RAM DDR5 5200 MHz, armazenamento SSD NVMe PCIe 4.0 de 512 GB e GPU dedicada NVIDIA® GeForce RTX 4050 com 6 GB de memória GDDR6 (TGP até 80W). A etapa de inferência utilizou aceleração por GPU. A captura de vídeo foi realizada em resolução *Full High Definition* (Full

HD, 1920×1080) configurada para 30 *Frames Per Second* (FPS). Considerando todo o pipeline do sistema — detecção facial, extração de *landmarks*, estimação geométrica, refinamento neural, suavização temporal e atualização do cursor — o desempenho observado variou entre 22 e 27 FPS, com média aproximada de 24.5 FPS. Na Tabela I, apresentam-se as métricas consolidadas do sistema completo em execução contínua, juntamente com faixas de referência consideradas ideais e aceitáveis para aplicações de rastreamento ocular baseadas em webcam Red-Green-Blue (RGB).

TABELA I
COMPARAÇÃO DO DESEMPENHO DO SISTEMA COM FAIXAS IDEAIS E ACEITÁVEIS PARA APLICAÇÕES DE RASTREAMENTO OCULAR EM TEMPO REAL

Métrica	Média Observada	Ideal	Aceitável
Latência por frame (ms)	40.8	≤ 33 ms	≤ 50 ms
FPS médio	24.5	≥ 30 FPS	≥ 20 FPS
Erro angular (graus)	3.2°	$\leq 2^\circ$	$\leq 4^\circ$
Desvio na tela (pixels)	5.4 px	≤ 3 px	≤ 8 px

Observa-se que o sistema operou dentro da faixa aceitável para interação humano-computador em tempo real (≥ 20 FPS), embora abaixo do regime ideal de 30 FPS. A latência média de 40.8 ms permanece dentro do limite aceitável para aplicações interativas. O erro angular médio de 3.2° encontra-se dentro da faixa aceitável para sistemas baseados em câmera RGB convencional, ainda que superior ao patamar ideal observado em soluções com hardware dedicado. De forma correspondente, o desvio médio de 5.4 pixels em resolução Full HD mantém-se dentro da margem tolerável para controle fino de cursor em

aplicações assistivas.

A capacidade de generalização do modelo foi avaliada utilizando três indivíduos que não estavam presentes nas aproximadamente 2300 imagens utilizadas no treinamento. Para cada participante, foi executado o procedimento completo de calibração multiponto, coletando amostras correspondentes aos cinco pontos da tela. A análise visual dos clusters de calibração revelou que a estrutura espacial dos cinco pontos foi preservada em todos os indivíduos, indicando que o modelo mantém coerência geométrica básica mesmo fora da distribuição de treinamento. Entretanto, observou-se aumento consistente na dispersão intra-cluster e deslocamento sistemático dos centróides estimados.

No primeiro indivíduo, os clusters apresentaram separabilidade razoável no eixo horizontal, porém com variância vertical moderada, indicando erro predominantemente associado à componente Y da regressão. No segundo indivíduo, observou-se maior degradação, com deslocamento vertical significativo e aumento expressivo da variância intra-cluster. Esse comportamento sugere limitação do modelo em capturar diferenças anatômicas específicas e variações interindividuais não representadas no dataset original. No terceiro indivíduo, os clusters permaneceram estruturalmente organizados, porém com deslocamento sistemático moderado no eixo horizontal, caracterizando degradação intermediária.

Quantitativamente, o erro angular médio variou entre 8° e 11°, enquanto o desvio médio em tela situou-se entre 14 e 19 pixels em resolução Full HD. Esses valores representam aumento aproximado entre 2.5 e 3.5 vezes em relação ao desempenho obtido no conjunto de validação interna. Apesar da redução de precisão espacial, o sistema manteve desempenho computacional estável, operando entre 22 e 27 FPS, demonstrando que a limitação observada está associada à capacidade de generalização do modelo e não a restrições de processamento ou captura de vídeo.

V. CONCLUSÃO E DISCUSSÃO

Este trabalho apresentou o desenvolvimento e a validação de um sistema de controle de cursor sem as mãos baseado em rastreamento ocular em tempo real utilizando apenas uma câmera RGB convencional. A arquitetura proposta combina detecção facial e extração de *landmarks* via *dlib*, estimação inicial da direção do olhar e um modelo neural totalmente conectado para refinamento espacial, compondo uma abordagem híbrida de baixo custo computacional.

A estratégia de calibração multiponto com repetição em ciclos consecutivos, aliada à normalização dos dados e à suavização temporal do cursor, mostrou-se eficaz na redução de erros sistemáticos e oscilações abruptas. Os resultados experimentais indicaram convergência estável do treinamento, baixo erro euclidiano normalizado e redução do *gap* treino-validação, evidenciando boa capacidade de generalização do modelo.

Observou-se que treinamentos curtos apresentam maior instabilidade de generalização, enquanto o uso de *learning rate schedulers* contribui significativamente para a convergência do modelo. Em particular, treinamentos prolongados com taxa de aprendizado controlada permitiram melhor desempenho e

maior precisão no mapeamento entre a região ocular e as coordenadas. Apesar de oscilações ocasionais relacionadas à configuração do *learning rate* e à variabilidade limitada do conjunto de dados, a integração entre calibração multiponto, regressão neural e suavização temporal resultou em um sistema estável para controle de cursor em tempo real.

Como principal contribuição, o trabalho demonstra que a combinação de técnicas clássicas de visão computacional com aprendizado profundo leve pode viabilizar sistemas de rastreamento ocular acessíveis, executados em tempo real e sem necessidade de hardware especializado. Como trabalhos futuros, pretende-se ampliar o conjunto de dados, investigar arquiteturas neurais mais robustas e incorporar novos mecanismos de interação, como detecção de piscadas e gestos oculares, além de realizar estudos de usabilidade com usuários.

AGRADECIMENTOS

Os autores agradecem ao Instituto Nacional de Telecomunicações (INATEL) pelo suporte estrutural e acadêmico para o desenvolvimento desta pesquisa. Este trabalho foi parcialmente financiado pelo Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq) e pela Fundação de Amparo à Pesquisa do Estado de Minas Gerais (FAPEMIG).

REFERÊNCIAS

- [1] D. W. Hansen e Q. Ji. "In the eye of the beholder: A survey of models for eyes and gaze". Em: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 32.3 (2010), pp. 478–500. URL: <https://ieeexplore.ieee.org/document/4770110>.
- [2] X. Zhang, Y. Sugano, M. Fritz e A. Bulling. "Appearance-based gaze estimation in the wild". Em: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2015, pp. 4511–4520. URL: https://openaccess.thecvf.com/content_cvpr_2015/papers/Zhang_Appearance-Based_Gaze_Estimation_2015_CVPR_paper.pdf.
- [3] X. Zhang, Y. Sugano, M. Fritz e A. Bulling. "It's written all over your face: Full-face appearance-based gaze estimation". Em: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*. 2017. URL: https://openaccess.thecvf.com/content_cvpr_2017_workshops/w41/papers/Bulling_Its_Written_All_CVPRW_2017_paper.pdf.
- [4] T. Fischer, H. J. Chang e Y. Demiris. "RT-GENE: Real-Time Eye Gaze Estimation in Natural Environments". Em: *Proceedings of the European Conference on Computer Vision (ECCV)*. 2018, pp. 334–351. URL: https://link.springer.com/chapter/10.1007/978-3-030-01249-6_21.
- [5] D. E. King. "Dlib-ml: A machine learning toolkit". Em: *Journal of Machine Learning Research* 10 (2009), pp. 1755–1758. URL: <http://jmlr.org/papers/v10/king09a.html>.
- [6] V. Kazemi e J. Sullivan. "One millisecond face alignment with an ensemble of regression trees". Em: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2014, pp. 1867–1874. URL: https://openaccess.thecvf.com/content_cvpr_2014/papers/Kazemi_One_Millisecond_Face_Alignment_2014_CVPR_paper.pdf.
- [7] Antoine Lamé. *GazeTracking: A Python library for eye tracking with OpenCV*. GitHub repository. 2020. URL: <https://github.com/antoinelame/GazeTracking>.
- [8] G. Bradski. "The OpenCV Library". Em: *Dr. Dobb's Journal of Software Tools* (2000). URL: <https://opencv.org/>.
- [9] Al Sweigart. *PyAutoGUI: Cross-platform GUI automation for human beings*. GitHub repository. 2015. URL: <https://github.com/asweigart/pyautogui>.
- [10] Adam Paszke et al. "PyTorch: An imperative style, high-performance deep learning library". Em: *Advances in Neural Information Processing Systems (NeurIPS)*. 2019. URL: <https://arxiv.org/abs/1912.01703>.
- [11] D. P. Kingma e Jimmy Ba. "Adam: A method for stochastic optimization". Em: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2015. URL: <https://arxiv.org/abs/1412.6980>.